

DA IODAA : Cours d'Apprentissage Artificiel

Exercice 1 : Les échantillons de Mars

1- Spécifiez le S-set et le G-set après la prise en compte de chacune des séquences

Les séquences d'exemple sont :

Exemple	Forme	Couleur	Composition	Classe
E1	Ellipsoïde	Orange	Amine	+
E2	Sphère	Rouge	Organo-phosphoré	+
E3	Pentaèdre	Vert	Sulfure	-
E4	Sphère	Rose	Amine	-

- **E1** : $S1 = \{(Ellipsoïde \ \& \ orange \ \& \ amine)\}$

$G1 = \{(? \ \& \ ? \ \& \ ?)\}$

- **E2** : $S2 = \{(Conique \ \& \ claire \ \& \ organique), (Conique \ \& \ foncée \ \& \ organique)\}$

$G2 = \{(? \ \& \ ? \ \& \ ?)\}$

- **E3** : $S3 = S2 = \{(Conique \ \& \ claire \ \& \ organique), (Conique \ \& \ foncée \ \& \ organique)\}$

$G3 = \{(Conique \ \& \ ? \ \& \ ?), \{(? \ \& \ chaude \ \& \ ?)\}, \{(? \ \& \ ? \ \& \ organique)\}\}$

- **E4** : $S4 = \{(Conique \ \& \ foncé \ \& \ organique)\}$

$G4 = \{(? \ \& \ foncé \ \& \ ?)\}$

Le S-set est donc : $\{(Conique \ \& \ foncé \ \& \ organique)\}$

Le G-set est donc : $\{(? \ \& \ foncé \ \& \ ?)\}$

2- Comment seront alors classés les exemples suivants et pourquoi ?

En supposant qu'il est préférable d'avoir des faux négatifs que des faux positifs, les nouvelles séquences pourraient être classées ainsi :

Exemple	Forme	Couleur	Composition	Classe
E5	Sphère	Marron	Cétone	+
E6	Sphère	Rouge	Oxyde	-
E7	Pentaèdre	Violet	Cétone	-

La séquence E5 aurait pour classe + car la "sphère" est une forme conique le "marron" est une couleur foncée, les "cétones" sont des organiques. Elle correspond donc parfaitement au S-set défini à la question précédente.

La séquence E6 aurait probablement pour classe - car même si la forme est conique, sa couleur est froide et sa composition est minérale comme dans le cas de la séquence E3 qui était de classe -.

La séquence E7 aurait peut-être pour classe - car même si cette fois-ci la couleur et la composition sont respectivement foncée et organique, la forme est un pentaèdre comme dans l'exemple 4 qui était de classe -.

Exercice 2 : Réflexions sur la fragmentation du G-set

1- Pourquoi le G-set peut facilement être de taille exponentielle en le nombre d'exemples d'apprentissage ?

G peut devenir très grand parce qu'un exemple négatif peut créer plusieurs spécialisations possibles, et chacune de ces spécialisations peut ensuite donner naissance à plusieurs autres spécialisations qui dans certains cas peuvent être chacune incomparable (chacune n'est pas plus spécifique que les autres). Cependant ces cas correspondent aux pires des cas lorsqu'il y a beaucoup d'attributs avec des hiérarchies complexes.

Ceci est une intuition cependant je n'ai pas réussi à trouver des exemples permettant d'illustrer ce phénomène.

2- Quel remède pourrait permettre de limiter de phénomène ? Réfléchissez en particulier à l'utilisation de near-miss (contre-exemples critiques). Quel effet ont-ils sur le G-set ?

Le near-miss correspond au fait de donner des exemples négatifs proches des exemples positifs.

Ceci permet de limiter ou diminuer les hypothèses possibles dans le G-set car cela permet d'éliminer les généralisations trop larges. En effet, le but du G-set et S-set sont de délimiter l'espace des versions possible. Exclure des hypothèses proches des hypothèses positives dont déjà incluses dans le S-set permettent donc rapprocher le G-set du S-set et donc d'aider à la convergence.