

Fiche récap — L'Évaluation de l'Apprentissage

Méthodes d'évaluation des systèmes d'apprentissage automatique — d'après le cours d'A. Cornuéjols

1. Pourquoi évaluer ?

L'induction est faillible : une hypothèse qui marche sur les données vues peut échouer sur des données nouvelles. 3 questions : quelle performance ? meilleur qu'un autre ? comment régler mon système ?

- **No free lunch** : pas de meilleur algo dans l'absolu, tout dépend du jeu de données.
- **Le taux d'erreur n'est qu'un critère parmi d'autres** (intelligibilité, coûts...) — s'y limiter peut aveugler.

2. Facteurs contrôlables / incontrôlables

- **Contrôlables** : l'algorithme, ses hyperparamètres (architecture, k et distance pour k-ppv, prétraitements).
- **Incontrôlables** : bruit, tirage aléatoire des données, initialisation aléatoire de l'algo → répéter les expériences pour obtenir une distribution.

Optimisation des hyperparamètres

Grid search, optimisation bayésienne, par gradient, algorithmes évolutionnaires.

- **Piège** : réglée sur le set de validation → sujette à overfitting ; un set de test séparé reste indispensable.

3. Matrice de confusion & indicateurs

VP/FP/FN/VN selon prédiction vs réalité (+ / -).

- **Sensibilité (rappel) = $VP/(VP+FN)$** : parmi les vrais +, combien retrouvés ?
- **Spécificité = $VN/(VN+FP)$**
- **Précision = $VP/(VP+FP)$** : parmi les + annoncés, combien vrais ?
- **Taux d'erreur = $(FP+FN)/m$; Accuracy = $1 - \text{taux d'erreur}$.**
- **F1 = $2 \times \text{Précision} \times \text{Rappel} / (\text{Précision} + \text{Rappel})$** (moyenne harmonique — pénalise fortement un score faible).

Exemple : SVM 70.1% accuracy vs NB 62.4% — mais le SVM sur-prédit la classe majoritaire (131 « good » prédits pour 105 réels) : l'accuracy seule masque ce biais. → toujours examiner la matrice complète.

4. Protocoles : apprentissage / validation / test

- **Apprentissage** : ajuste les paramètres. **Validation** : règle les hyperparamètres. **Test** : estime la performance finale (jamais utilisé avant).
- **Sur-apprentissage** : erreur train ↓ continûment, erreur validation ↓ puis remonte → arrêt précoce au minimum de validation.

Risque réel vs empirique

$$e_D = \int_D |y - f(x, \theta)| p(x, y) dx, y \quad (\text{inaccessible})$$

$$\hat{e}_S = (1/m) \sum |y - f(x, \theta)| \quad (\text{calculable sur } T)$$

5. Intervalles de confiance

Nb d'erreurs ~ loi binomiale ; approchée par une loi normale si $np(1-p) \geq 5$.

$$\text{erreur}_T(h) \pm z_N \sqrt{[\text{erreur}_T(1 - \text{erreur}_T)/n]}$$

$$z_N : 50\% \rightarrow 0.67 \cdot 90\% \rightarrow 1.64 \cdot 95\% \rightarrow 1.96 \cdot 99\% \rightarrow 2.58$$

- **Exemple** : 12/40 erreurs → $\hat{e} = 0.3$, IC95% = [0.16 ; 0.44] (large car n petit).
- **Comparer 2 modèles** : $\hat{d} = \hat{e}_1 - \hat{e}_2$, IC95% = $\hat{d} \pm 1.96 \sqrt{[\hat{e}_1(1 - \hat{e}_1)/m_1 + \hat{e}_2(1 - \hat{e}_2)/m_2]}$.

6. Peu de données : validation croisée

- **k-fold** : k parties, chacune sert 1 fois de test, erreur = moyenne des k erreurs.
- **Leave-one-out** : k=n. Faible biais, haute variance, sous-estime l'erreur si non i.i.d.
- **Bootstrap** : tirage avec remise ; $\hat{R} = 0.636 \times \bar{P}_1 + 0.368 \times \bar{P}_2$.

Problème commun : les estimations successives sont dépendantes → IC calculés naïvement trop optimistes.

7. La courbe ROC

- **Erreur type 1 (α)** : faux positifs. **Erreur type 2 (β)** : faux négatifs.

Seuil T sévère → moins de FP, plus de FN (et inversement) : aucun seuil ne minimise les deux à la fois.

- **ROC** = TPR (ordonnée) vs FPR (abscisse) pour tout $T \in [0, 1]$. Diagonale = hasard (pertinence 0,5) ; plus proche du coin (0,1), meilleur le classifieur.

8. Autres mesures & critères

Matrice de confusion multi-classes : diagonale = bien classés, hors-diagonale = confusions entre classes (ex. 14% papillons pris pour poissons).

- **Au-delà du taux d'erreur** : intelligibilité des résultats, performances en généralisation, coûts (préparation, calcul, expertise apprentissage, expertise domaine).

9. Résumé

- **Soignez votre fonction de coût** (pas seulement le taux d'erreur brut).
- **Calculez les intervalles de confiance** sur données finies.
- **Données rares → validation croisée** (k-fold, LOO, bootstrap).
- **N'oubliez jamais l'ensemble de test**, distinct de la validation.
- **Gardez l'esprit critique** face à des résultats trop beaux.

Réf. : Japkowicz & Shah, *Evaluating Learning Algorithms* (Cambridge University Press, 2011). D'après le cours d'A. Cornuéjols, AgroParisTech (basé sur S. Thrun, CMU, et P. Cunningham, ECML-09).