

Fiche récap — Réseaux de neurones : Deep Learning & architectures avancées

D'après le cours d'A. Cornuéjols (AgroParisTech) — diapositives 96 à 153

1. Vers les réseaux profonds : l'ancêtre des CNN

Problème fondateur : lire des codes postaux manuscrits (Le Cun et al., 1989). 2 idées clés vs. PMC classique :

- **Partage de poids** : un même détecteur de trait (ex. bord à 45°) réutilisé partout dans l'image.
- **Optimal brain damage** : élagage des connexions les moins utiles après coup.

Convolution

Filtre (petite grille de poids, ex 3×3) glissé sur l'image ; à chaque position, somme pondérée des pixels recouverts → «carte de traits» (feature map). Même calcul qu'un neurone classique, mais local + poids partagés → invariance par translation, peu de paramètres.

Max-pooling

Découpe la carte en blocs (ex 2×2), ne garde que le max de chaque bloc → réduit la taille des données, robustesse aux petits décalages.

Pipeline CNN type

[Convolution → Pooling] répété plusieurs fois → classifieur MLP + softmax final. Les filtres sont appris par rétropropagation, comme les poids d'un PMC classique (seule différence : contrainte de structure).

2. Choix de représentation des entrées

Principe : «l'apprentissage devient facile quand on sait déjà quoi chercher». 2 questions : quel type de tâche ? comment coder les exemples (pixels bruts vs descripteurs faits main) ? Intérêt des CNN : apprennent les descripteurs eux-mêmes, directement à partir des pixels bruts.

3. Architectures emblématiques

- **LeNet-5** : conv/activation → pooling → couches complètement connectées → softmax. Référence historique (caractères).
- **ImageNet** : >15M images, ~22 000 catégories, étiquetées via Mechanical Turk.
- **AlexNet (2012)** : tournant du deep learning. Ex. : 1re couche conv (filtres 11×11, stride 4, entrée 227×227×3) → 55×55×96 neurones, 363 poids+biais chacun → 105 705 600 paramètres rien que pour cette couche.
- **U-Net** : segmentation pixel par pixel. Architecture en U symétrique : descente (résolution ↓, nb filtres ↑) puis montée (reconstruction), connexions «copy and crop» entre les 2 branches.
- **GoogleNet** : assemblage sophistiqué de blocs convolutionnels, passage à très grande échelle (ex. Google/Stanford : 9 couches, ~10⁹ connexions, 10M images, 16 000 processeurs, 3 jours).

4. Que représentent les neurones cachés ?

- **Feature visualization** : on optimise l'image d'entrée (au lieu des poids) pour maximiser l'activation d'un neurone — permet de «voir» ce à quoi il répond.
- **Représentations hiérarchiques** : couche 1 = bords/contrastes locaux ; couche 2 = parties (œil, nez...) ; couche 3 = objets entiers (visage). Idem pour la parole/texte : régularités locales → sémantique de haut niveau.

5. Manque de données étiquetées : les parades

- **Data augmentation** : transformations simples (bruit, flou, rotation, translation...) qui préservent l'étiquette ; ou GANs (puissant mais délicat à utiliser).
- **Auto-encodage** : encodeur (x → embedding compressé) + décodeur (embedding → $\hat{x} \approx x$). Apprentissage «supervisé» sans étiquette humaine (la cible est x lui-même).
- **Auto-apprentissage (self-supervised)** : tâche annexe (pretext task) fabriquée à partir des données brutes, ex. prédire la position relative de 2 patches d'une image — force le réseau à apprendre la structure des données.

6. Stabiliser / régulariser l'apprentissage

- **Batch norm** : normalise chaque descripteur sur le lot d'exemples courant.

- **Layer norm** : normalise chaque exemple sur ses propres descripteurs.
- **L2-norm** : projette les sorties sur une sphère de norme constante.
- **Dropout** : désactive aléatoirement une fraction des neurones à chaque itération d'entraînement → évite la co-adaptation, force des représentations redondantes/robustes. Tous les neurones réactivés au test.

7. Résultat troublant sur la généralisation

Zhang, Bengio, Hardt, Recht & Vinyals (ICLR 2017). CIFAR-10 + AlexNet, 3 conditions :

- **Données réelles** : train = 100 %, test = 89 % (normal).
- **Étiquettes aléatoires** : train = 100 % quand même !
- **Pixels aléatoires (bruit pur)** : train = 100 % encore !

→ Un réseau profond peut mémoriser n'importe quoi, même sans structure. Contredit l'intuition classique du compromis biais-variance. Question ouverte : pourquoi généralise-t-il si bien sur de vraies données plutôt que de mémoriser le bruit ? La théorie classique (biais-variance, VC-dimension) ne suffit pas à l'expliquer.

8. Autres architectures

- **Reservoir computing** : grand réseau récurrent à poids fixes aléatoires (jamais entraînés) ; seule la couche de lecture (readout) est entraînée par régression linéaire. Réintroduit une dynamique temporelle sans les instabilités de la rétropropagation sur séquences longues.
- **Réseaux impulsionnels (spiking NN)** : neurones communiquant par impulsions discrètes (spikes) ; potentiel qui s'accumule et déclenche un spike au-delà d'un seuil. Plus fidèle à la biologie, mais événement discret → difficile à entraîner par descente de gradient classique.

9. Bilan général

- **Méthode très versatile** mais pas un modèle biologique fidèle malgré l'inspiration initiale.
- **Apprentissage exigeant** : choix d'architecture empirique, lent, minima locaux.
- **Opacité persistante** : difficile à interpréter, difficile d'y injecter de la connaissance a priori.

Réf. : Barra, Cornuéjols & Miclet (Eyrolles 2021) · Bishop & Bishop (Springer 2023) · Haykin (Prentice Hall 1999) · Raschka et al. (Packt 2022) · Torralba et al. (MIT Press 2024). D'après le cours d'A. Cornuéjols, AgroParisTech.