

Introduction à l'Apprentissage Automatique

Fiche de révision — logique du cours (A. Cornuéjols)

1. Pourquoi apprendre ?

Def (Tom Mitchell, 2006) : construire des systèmes qui s'améliorent **automatiquement avec l'expérience.**

On apprend plutôt que coder quand un concept est **difficile à coder à la main** (ex : reconnaître un chien, prédispositions à un cancer).

3 grandes familles d'applications :

- **Reconnaissance/prédiction :** images (lésions de peau), séries temporelles (bourse, météo)
- **IA générative :** AlphaFold (protéines), ITHACA (archéologie, 62% vs 25% experts), GPT/génération d'images
- **IA agentique :** systèmes autonomes qui agissent dans leur environnement (ex. Co-Scientist)

Loi fondamentale : il faut des exemples **d'erreurs** pour vraiment apprendre.

Limites : *adversarial learning* (bruit sur pixels trompe l'IA) ; *problème d'explicabilité des réseaux profonds (pourquoi se trompent-ils ?)*.

2. Brève histoire de l'IA — dates clés

1943 McCulloch & Pitts → 1er modèle formel de neurone

1948 Cybernétique : Shannon (info/codage), Wiener

1936-56 Pionniers : Turing, Von Neumann, Hebb (1949)

1956-68 Raisonnement général : IA symbolique (CHECKER, démonstrateurs) vs. 1er connexionnisme (Perceptron, Rosenblatt 1957-62). Échecs : XOR, traduction auto, experts non universels

1968-80 "Knowledge is power" : représentation des connaissances, systèmes experts (CYC). Pb : acquérir/généraliser les connaissances

1980-95 Méthodes générales d'apprentissage : symbolique (arbres décision, espace versions) + renouveau connexionniste (Hopfield 1982, PMC 1985)

1995-2011 Apprentissage statistique (i.i.d.), SVM, Boosting

2012-... Réseaux profonds : CNN, GANs, LLM

2022-... IA générative/agentique, retour possible de la connaissance (causalité)

Symbolique vs Connexionnisme

SYMBOLIQUE manipuler des règles/symboles **explicites**, lisibles par un humain.

CONNEXIONNISME apprendre les **poids** d'un réseau de neurones (boîte noire).

→ **Différence : explicite/interprétable vs appris/opaque — le connexionnisme gère mieux le bruit et le monde réel.**

3. Les 4 grands types d'apprentissage

DESCRIPTIF (NON SUPERVISÉ)

À partir de données brutes, **sans étiquettes**, trouver des régularités qui les résument (clusters, motifs fréquents) — pour explorer et comprendre, sans savoir à l'avance ce qu'on cherche. Dépend fortement du **biais a priori**.

Ex : *clustering de consommateurs (Nutrinet) ; motifs fréquents (pizza+coca+glace).*

PRÉDICTIF (SUPERVISÉ)

À partir d'exemples où entrée et sortie sont déjà liées (**x, y**), faire apprendre à la machine la fonction qui les relie, pour ensuite **prédire y** à partir de nouveaux x.

Discrimination (classe) vs **Régression** (valeur continue).

Ex : *spam/pas spam ; filtrage d'articles GIEC ; accidents ~ ancienneté permis (régression) ; pathologie d'un patient ; chat vs chien.*

PRESCRIPTIF ("INTERVENIR")

Chercher des liens de **causalité** (pas juste de corrélation) pour savoir quelle action entreprendre — "que se passerait-il si j'intervenais ainsi ?"

Ex : *piège glaces/maillot de bain (corrélation ≠ causalité) ; impact d'un doublement de prix ; rendement si autre culture plantée.*

PAR RENFORCEMENT

Un agent apprend, **par essais-erreurs**, à agir dans un environnement (perception → action → récompense) de façon à **maximiser un gain à long terme**. Proche de l'apprentissage de réflexes.

Ex : *AlphaGo, hélicoptère, tennis de table, backgammon (1992), portefeuille d'investissement. Fragile à tout changement de paramètres (ex. le tireur de penalty face à un gardien imprévisible).*

ORGANISATION DES DONNÉES

Un exemple = une ligne (instance) ; les colonnes = descripteurs/attributs (*features*) ; la dernière colonne = étiquette/label.

Types de données : vectorielles, séquences, structurées, temporelles, spatiales.

4. Problème de l'apprentissage supervisé

INDUCTION

Induction : généraliser à partir d'exemples particuliers pour en tirer une règle générale (ex : "qq émeraudes vertes" → "toutes vertes"). **Nécessite toujours un biais** — sans lui, aucune généralisation n'est justifiée.

Ex chiffré : 4 attributs binaires → $2^{16} = 65\,536$ fonctions possibles ; il en reste $2^{10} = 1\,024$ après 6 exemples → sans biais, on ne peut pas trancher.

Double question : 1) invention (trouver les règles) 2) justification (les garantir).

Citation (Valiant, 2013) : l'induction est aussi routinière/reproductible que la chute des objets sous la gravité.

LE BIAIS

Biais = ce qui limite et favorise certaines hypothèses dans l'espace des hypothèses.

REPRÉSENTATION (déclaratif) : limite l'espace H considéré.

RECHERCHE (procédural) : ordre d'exploration qui favorise une hypothèse.

SOUS/BON/SUR-APPRENTISSAGE

Sous-apprentissage : h trop simple, ne capture pas la structure. **Bon apprentissage :** h capture la vraie structure sans coller au bruit. **Sur-apprentissage :** h colle trop aux exemples (bruit inclus), généralise mal.

No Free-Lunch Theorem

En moyenne sur **tous** les problèmes possibles, tous les algos ≈ le hasard. **Pas d'algo universellement meilleur** → choisir le bon biais selon la classe de problèmes.

GARANTIES "DE LAMPADAIRE"

Si le monde satisfait nos hypothèses (le biais), **alors** bonne hypothèse garantie.

Sinon (monde pas "parcimonieux") : risque de très mauvaise hypothèse, aucune garantie.

Image : l'ivrogne qui cherche ses clés sous le lampadaire — pas où il les a perdues, mais là où il y a de la lumière.

Les 3 ingrédients de l'apprentissage

1. Espace des hypothèses H (généralement $H \neq F$, l'espace de toutes les fonctions).

2. Critère inductif : comment évaluer chaque hypothèse selon S.

3. Méthode d'exploration de H : comment trouver une bonne hypothèse.