

Le Machine-Learning en pratique

Introduction générale — Gulgue & Thoreau, AgroParisTech / INRAE / Université Paris-Saclay

1. Cadres du Machine Learning

Supervisé : exemples étiquetés (X, Y) connus → apprendre f : X→Y

Non-supervisé : pas d'étiquettes → structure cachée dans X

Semi-supervisé : quelques étiquettes + beaucoup de données brutes

Renforcement : agent, perception/action, récompense

Différents algorithmes, différentes données, différents coûts, différentes évaluations.

Nouvelle donne : crowdsourcing (Amazon Mechanical Turk).

2. Familles de problèmes supervisés

Classification Régression Ranking Generative AI

- **Classification** : séparer des classes discrètes
- **Régression** : interpolation / forecasting (valeur continue)
- **Ranking** : ordonner des documents/objets
- **Generative AI** : prédire une sortie structurée Y à partir de X

Beaucoup d'applications ≠ peu de problématiques générales sous-jacentes.

3. Chaîne de traitement type

Jeu de données → **Extraction de caractéristiques** (X, colonnes) + **Supervision** (Y) → **Apprentissage** → **Classifieur/Modèle** → **Inférence** sur nouvelle donnée → **Évaluation**

$$f(x) = \sum_j \alpha_j x_j$$

- Sélection des bonnes colonnes (variables)
- Ajout de colonnes intéressantes (calculs, sources externes...)

⚠ **L'évaluation est aussi importante que le modèle !**

Sans mesure = pas de sens · Perf. fausse = danger · Perf. basse = difficile à vendre.

Analyse des perfs ⇒ modèle v2 (itération).

4. Panorama des modèles de ML

Historiques

- **Arbres de décision** : entre IA symbolique & stats, interprétables, règles
- **Modèles bayésiens** : lois de proba, max. de vraisemblance, Naive Bayes, a priori experts

Les "bonnes affaires"

- **Modèles linéaires** : moindres carrés (MSE), régression logistique — simples, efficaces, descente de gradient
- **SVM / noyaux** : perceptron, régularisation, projection non-linéaire (kernel trick)

Non-supervisé

- **Densité** : Parzen, Nadaraya-Watson, k-NN, EM
- **Clustering** : hiérarchique, k-means/C-EM, spectral, a priori

État de l'art

- **Ensembleistes** : Bagging, Boosting, Random Forest, XGBoost
- **Réseaux de neurones** : perceptron, rétropropagation, architectures (pytorch)

5. Focus — Arbres de décision

Notations : espace X = R^d, exemples x_i, étiquettes Y (binaire : {0,1} ou {-1,1})

Principe : nœud = test d'une variable, branche = résultat du test, feuille = étiquette y

Algo glouton top-down : si nœud impur → trouver la meilleure variable X_j et son test, créer les fils, répartir les exemples ; sinon → feuille

$$H(X) = -\sum_i P(X=x_i) \cdot \log(P(X=x_i))$$

Entropie ↑ = désordre ↑. Entropie nulle = classification parfaite.

$$\textit{Gain d'info } I(T,Y) = H(Y) - H(Y|T) \Rightarrow \textit{à maximiser } (\Leftrightarrow \textit{minimiser } H(Y|T))$$

Cas discret : partition directe par modalité. **Cas continu** : test de tous les seuils de coupure possibles (tri + calcul entropie + conservation du meilleur seuil).

Toujours d'actualité via Random Forest, XGBoost, CatBoost.

6. Focus — SVM

$$L = \sum_i (1 - y_i f(x_i))_+ + C \|w\|^2$$

Coût charnière (hinge loss) ; (a)₊=max(a,0). Régularisation via hyper-paramètre C.

Forme duale : f(x_i) = ∑_j w_j·k(x_i,x_j) — noyau k linéaire, polynomial, gaussien...

Vecteurs supports : seuls les points sur/dans la marge déterminent la frontière

Multi-classes : one-vs-all ⇒ k* = argmax_k f_k(x) (attention aux cas de rejet : 0 ou plusieurs f_k>0.5)

Référence des années 90-2000. Extension régression = SVR. Limite : passage à l'échelle O(n²) à O(n⁴).