

1. Métriques d'évaluation

Tâche	Métrique
Régression	MSE / RMSE, MAPE (et sMAPE si y=0)
Classification	Accuracy, NLL
Discriminant	Perceptron / SVM (hinge loss)

⚠ Ne pas confondre métrique d'évaluation & coût optimisé pendant l'apprentissage.

2. Classification : matrice de confusion

Compter bien/mal classé, comprendre les confusions (cas binaire & multi-classe, ex. USPS).

Détection d'événement (classe rare)

$$Précision = TP/(TP+FP) \quad | \quad Rappel = TP/(TP+FN)$$

$$F1 = 2 \cdot (précision \cdot rappel) / (précision + rappel)$$

Agrégation : macro-moyenne (moyenne non pondérée par classe) vs micro-moyenne (pondérée par échantillons).

Classes déséquilibrées (ex. fraude CB : 0.3‰) : un modèle "tout OK" peut afficher 99% d'accuracy — la métrique ment ! → besoin de précision/rappel/F1, courbe ROC/AUC.

3. Courbes ROC & Précision/Rappel

ROC (receiver operating characteristic) : capacité à détecter les événements en faisant varier la sensibilité → **AUC** (Area Under Curve) résume la courbe.

Un seul classifieur ⇒ en réalité une famille de classifieurs biaisés selon le seuil choisi.

Autres tâches (ranking) : distance de Levenshtein, MRR, Mean Average Precision, nDCG, ATOP.

4. Processus d'évaluation robuste

Évaluer sur train = **tricherie** (surestimation). Évaluer sur données vierges = OK.
Validation croisée : K itérations train/test → K modèles, K perfs → moyenne robuste.
• Implémentation : split manuel + boucle, ou score CV direct (boucle cachée)
Significativité : peu de données (<50) → stats avancées ; beaucoup (>10000) → presque toujours significatif ; cas intermédiaire → test de Student sur CV.
Coûteux mais indispensable — parallélisable (option n_jobs).

5. Sélection de modèles

Approche théorique (critères d'information)

$$BIC = \log(n)k - 2\log(L) \quad | \quad AIC = 2k - \log(L)$$

Compromis complexité (k paramètres) / vraisemblance (L). Utile pour modèles probabilistes ; peu efficace en pratique sauf modèles simples (ex. AR).

Approche empirique

Tester modèles de référence (Naive Bayes, Régression logistique, SVM, Decision Tree) + modèles avancés (Random Forest, Gradient Boosting, réseaux de neurones) → comparer les perfs.

Outils pratiques

Grille de paramètres S + boucle *for* + score (test, CV, séparabilité de Fisher...) → **Grid Search**. En pratique : tâtonnement manuel puis grille fine sur les paramètres les plus sensibles.

6. Fléau de la dimensionnalité

Croyance naïve : plus d est grand, mieux c'est. **Faux** : ex. moindres carrés avec d>n → système mal posé (rang n < d inconnues).
Ajout de dimensions bruitées → distances euclidiennes s'aplatissent (points ~équidistants sur une hypersphère) → **train ↑, test ↓** = overfitting.

7. Sélection de variables (3 familles)

1. **Choisir/éliminer** : expert, introspection (poids du modèle), extrospection (test de sous-ensembles)
2. **ACP/PCA** : combinaisons d'axes expliquant la variance
3. **Apprendre à éliminer pendant l'apprentissage** (régularisation)
(0) Corrélation $X_j^T Y$ — naïf mais à tester ; limite : ignore le non-linéaire et les corrélations entre variables ($X_j \approx X_k$).
(1a) Poids d'un classifieur linéaire (SVM, régression logistique, Ridge) — hiérarchie informative mais bruitée.
(1b) Feature importance des forêts (fréquence d'usage, position racine/feuilles).
(1c) Itératif glouton : *Backward Elimination* (part de tout, retire) / *Forward Selection* (part de rien, ajoute) — coût élevé, early stopping.
(2) ACP : valeurs propres = force explicative, axes orthogonaux ; utile aussi pour visualisation (réseaux de capteurs, Iris 4D...).

8. Régularisation

Type	Formule (pénalité)	Effet
L2 (Ridge)	$C\ w\ ^2$	Affaiblit les poids (≠ annulation)
L1 (LASSO)	$C\ w\ _1 = C\sum w_j $	Annule les poids (sélection)
Elastic Net	$C_1\ w\ _1 + C_2\ w\ ^2$	Combine confort L2 + sélection L1

Cas limites : C=0 → moindres carrés ; C→∞ → w=0. En pratique C1 (Elastic Net) reste quasi epsilon, on règle surtout C2.

Protocole App / Val / Test : avec plusieurs hyper-paramètres, évaluer sur le test à chaque réglage = sur-apprentissage du test !
→ Sélection de modèle sur **(X_val, y_val)**, évaluation finale unique sur **(X_test, y_test)**.